Lab 12 — ¿Por qué 8 núcleos no son 8× más rápido?

Computación Paralela y Distribuida (CC3069)

Javier Eduardo España Pacheco

Universidad del Valle de Guatemala

Repositorio: https://github.com/Javier-Espana/LabSpeedUp-CPD.git

Octubre 2026

Índice

1. Datos del equipo **3**
1.1. Especificaciones de CPU . . . 3

2. Parte 1 — La parte que no se puede repartir (Ley de Amdahl) **3**
2.1. Predicciones antes del experimento . . . 3
2.2. Resultados — Tabla Parte 1 . . . 4
2.3. Cálculo a mano — dos filas . . . 4
2.4. Gráficas . . . 5
2.5. Preguntas . . . 6

3. Parte 2 — ¿Vale la pena paralelizar algo pequeño? **7**
3.1. 2a. El T_s honesto . . . 7
3.2. 2b. Sumar N números . . . 8

4. Parte 3 — Cuando a un hilo le toca más trabajo (Desbalance) **9**
4.1. Predicción . . . 9

5. Parte 4 — ¿Y si el problema crece con los núcleos? (Gustafson) **11**
5.1. Predicción . . . 11

6. Síntesis — Fugas de eficiencia **13**

7. Reto Opcional — Speedup Superlineal ($S > p$) **14**
7.1. Descripción del cambio en el código . . . 14
7.2. ¿Por qué ocurre el speedup superlineal? . . . 14
7.3. Resultados — 5 corridas consecutivas . . . 14

8. Capturas de evidencia **15**

1. Datos del equipo

1.1. Especificaciones de CPU

Cuadro 1: Datos del procesador (obtenidos con `lscpu`)

Campo	**Valor**
Modelo de CPU	AMD Ryzen 5 8400F 6-Core Processor
Arquitectura	x86_64
Familia / Modelo / Revisión	25 / 117 / 2
Núcleos físicos	6
Hilos por núcleo (SMT)	2
Núcleos lógicos (CPUs)	12
Núcleos de rendimiento/eficiencia	N/A (todos de rendimiento — AMD no usa big.LITTLE)
Hyper-Threading / SMT	Sí (2 hilos/núcleo)
Frecuencia máx.	4,758 GHz
Turbo Boost	Habilitado
Caché L1d	192 KiB (6 × 32 KiB)
Caché L1i	192 KiB (6 × 32 KiB)
Caché L2	6 MiB (6 × 1 MiB, privada por núcleo)
Caché L3	16 MiB (compartida)
Virtualización	AMD-V

Con este hardware, `pmax = 12` (6 núcleos × 2 hilos SMT).

2. Parte 1 — La parte que no se puede repartir (Ley de Amdahl)

2.1. Predicciones antes del experimento

Con $f_p = 1{,}00$: Todo el trabajo es paralelizable; la predicción de Amdahl es $S(12) = 12$. En la práctica espero un valor menor debido al overhead de crear y sincronizar hilos, y porque los núcleos SMT comparten recursos.

Con $f_p = 0{,}90$: Aplicando la ley de Amdahl:

$$S(12) = \frac{1}{1 - 0{,}90 + \dfrac{0{,}90}{12}} = \frac{1}{0{,}10 + 0{,}075} = \frac{1}{0{,}175} \approx 5{,}71$$

2.2. Resultados — Tabla Parte 1

Cuadro 2: Speedup (S), eficiencia (E) y mejor p para F máxima. CPU: 12 hilos lógicos ($p_{\text{máx}} = 12$).

f_p	$S(p=2)$	$S(p=4)$	$S(p=12)$	$E(p=12)$	p con F máx
1.00	1.983	3.958	8.233	0.686	11
0.95	1.884	3.428	7.087	0.591	11
0.90	1.799	3.056	5.487	0.457	10
0.75	1.591	2.246	3.080	0.257	3
0.50	1.311	1.570	1.786	0.149	1

2.3. Cálculo a mano — dos filas

Fila $f_p = 0{,}90$, $p = 4$

De los datos CSV (`amdahl_fp90.csv`):

$$T_s = 0{,}496348\,\text{s}, \quad T_p(4) = 0{,}162429\,\text{s}$$

$$S = \frac{T_s}{T_p} = \frac{0{,}496348}{0{,}162429} = \mathbf{3{,}056}$$

$$E = \frac{S}{p} = \frac{3{,}056}{4} = \mathbf{0{,}764}$$

$$C = p \cdot T_p = 4 \times 0{,}162429 = \mathbf{0{,}6497}\,\text{hilo-s}$$

$$F = \frac{S}{C} = \frac{3{,}056}{0{,}6497} = \mathbf{4{,}703}\,\text{speedup/hilo-s}$$

Fila $f_p = 1{,}00$, $p = 12$

$$T_s = 0{,}494336\,\text{s}, \quad T_p(12) = 0{,}060046\,\text{s}$$

$$S = \frac{0{,}494336}{0{,}060046} = \mathbf{8{,}233}$$

$$E = \frac{8{,}233}{12} = \mathbf{0{,}686}$$

$$C = 12 \times 0{,}060046 = \mathbf{0{,}7206}\,\text{hilo-s}$$

$$F = \frac{8{,}233}{0{,}7206} = \mathbf{11{,}425}\,\text{speedup/hilo-s}$$

2.4. Gráficas

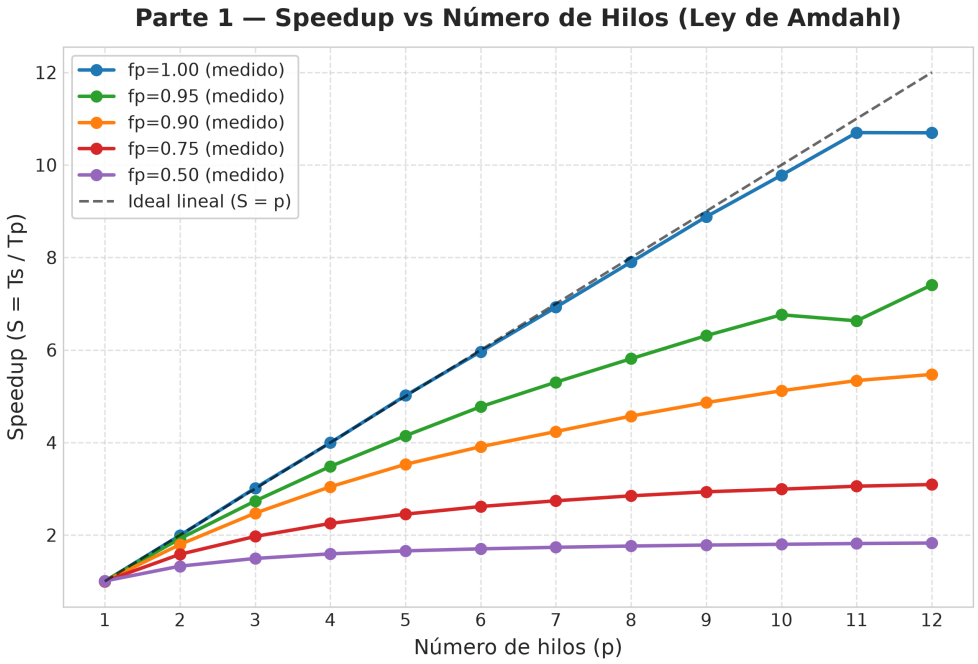


Figura 1: Speedup vs. número de hilos para distintos valores de f_p.

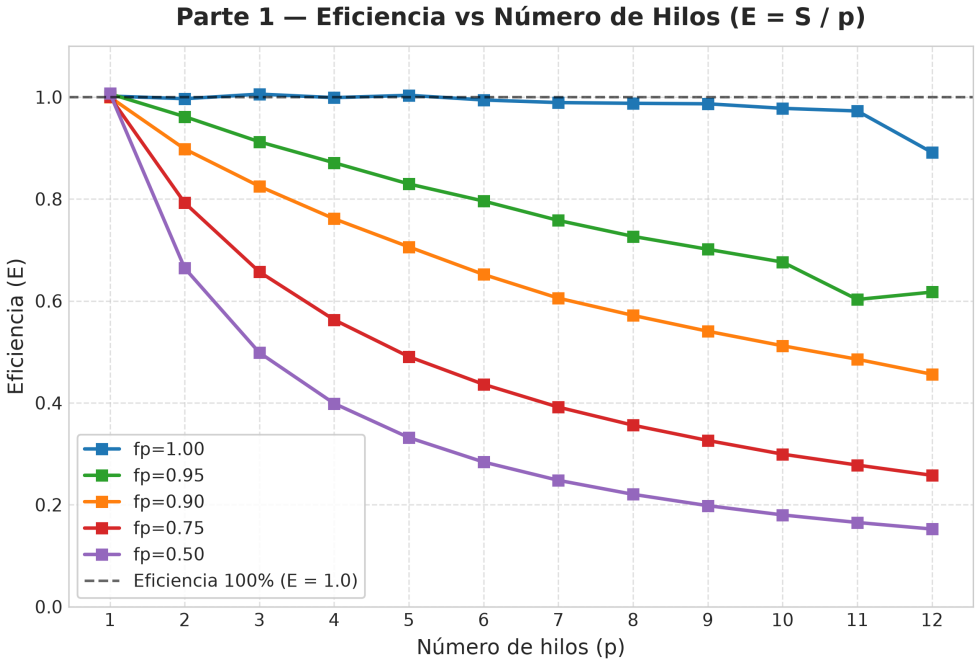


Figura 2: Eficiencia $E = S/p$ vs. número de hilos.

2.5. Preguntas

1. **Con $f_p = 1{,}00$, ¿llegaste a $S = p$?**
   No. Se midió $S(12) = 8{,}233$ en lugar del ideal 12. Las causas son:

   - **Hyper-Threading (SMT):** los 6 núcleos físicos comparten recursos de ejecución entre sus 2 hilos lógicos (unidades de enteros, caché L1/L2). Al usar los 12 hilos lógicos, los 6 pares compiten por recursos → eficiencia degradada. Esto encaja en η_c (overhead de sincronización y recursos compartidos).
   - **Turbo Boost escalonado:** con un solo hilo la CPU puede alcanzar su máxima frecuencia (∼4.76 GHz), pero con 12 hilos la potencia se reparte y la frecuencia baja a ∼4.1–4.3 GHz. Esto no encaja limpiamente en ninguna de las cuatro fugas estándar.
   - **Overhead de creación/sincronización de hilos:** barrera implícita al final del `parallel for`. Encaja en η_c.

2. **Forma de la curva con $f_p = 0{,}75$:**
   La curva sube rápido al principio pero pronto se aplana. La ganancia de pasar de 1 a 2 hilos es $\approx 0{,}59$, pero de 11 a 12 hilos es prácticamente cero (S casi no cambia). La fracción secuencial del 25 % domina y limita el speedup máximo teórico a $1/0{,}25 = 4{,}0$, que nunca se alcanza.

3. **Derivación del modelo (Ley de Amdahl):**
   Un programa tarda T_1 en un núcleo. La fracción f_p se divide en p hilos y la fracción $(1 - f_p)$ es secuencial:

$$T_p = (1 - f_p)\, T_1 + \frac{f_p \cdot T_1}{p}$$

$$S(p) = \frac{T_1}{T_p} = \frac{T_1}{(1 - f_p)T_1 + \dfrac{f_p T_1}{p}} = \frac{1}{(1 - f_p) + \dfrac{f_p}{p}}$$

4. **Predicción con el modelo vs. lo medido ($f_p = 0{,}90$, $p = 12$):**

$$S_{\text{modelo}}(12) = \frac{1}{0{,}10 + 0{,}90/12} = \frac{1}{0{,}10 + 0{,}075} = \frac{1}{0{,}175} \approx 5{,}71$$

   Medido: $S = 5{,}487$. Diferencia de $\approx 4\,\%$; el modelo sobreestima ligeramente porque no considera el overhead de SMT ni la reducción de frecuencia.

5. **Límite cuando $p \to \infty$ con $f_p = 0{,}90$:**

$$\lim_{p \to \infty} S(p) = \frac{1}{1 - f_p} = \frac{1}{0{,}10} = \mathbf{10}$$

   Con 1000 núcleos el speedup máximo posible sería ≈ 10, no 1000.

6. **Despejando f_p real del speedup medido:**
   $S_{\text{medido}} = 5{,}487$, $p = 12$:

$$5{,}487 = \frac{1}{(1-f_p) + f_p/12} \Rightarrow (1-f_p) + f_p/12 = \frac{1}{5{,}487} = 0{,}1822$$

$$1 - f_p + f_p/12 = 0{,}1822 \Rightarrow 1 - 0{,}9167\, f_p = 0{,}1822 \Rightarrow f_p = \frac{0{,}8178}{0{,}9167} \approx 0{,}892$$

   El f_p efectivo medido es $\approx 0{,}892 < 0{,}90$. La diferencia (0,008) representa las fugas η_c (overhead de sincronización).

7. **Efectividad F con $f_p = 0{,}90$:**
   F es máxima con $p = 10$ ($F = 5{,}33$). Este no es el mismo p que da el menor tiempo ($p = 12$, $T_p = 0{,}090\,\text{s}$). Con $p = 10$ se obtiene el mejor balance entre rapidez y costo. Con 16 números en clase el óptimo era $p = 4$; aquí el problema más grande desplaza el óptimo a p mayor.

8. **Servidor de 64 núcleos para un programa de 20 s con 2 s secuenciales:**
   $f_p = 18/20 = 0{,}90$, fracción secuencial = 0,10.

$$S(64) = \frac{1}{0{,}10 + 0{,}90/64} = \frac{1}{0{,}10 + 0{,}01406} \approx 8{,}82$$

$$E(64) = \frac{8{,}82}{64} \approx 0{,}138$$

   Respuesta: el servidor de 64 núcleos solo daría $\approx 8{,}8\times$ de speedup (no $64\times$), con una eficiencia muy baja del 13.8 %. Solo se justifica si el costo del servidor es bajo; de lo contrario, un servidor de 8–10 núcleos con $E \approx 0{,}50$ sería más costo-efectivo.

3. Parte 2 — ¿Vale la pena paralelizar algo pequeño?

3.1. 2a. El T_s honesto

De `amdahl_fp100.csv`, fila $p = 1$:

- `t_seq` = 0.494336 s (versión sin OpenMP)
- `t_par` con $p = 1$ = 0.493555 s (OpenMP, 1 hilo)

1. En esta máquina `t_par`($p = 1$) es prácticamente igual a `t_seq` ($\Delta \approx 0{,}16\,\%$). El overhead de inicializar el entorno OpenMP es insignificante para trabajos grandes.

2. Si se usa como T_s el tiempo del programa paralelo con 1 hilo, el speedup sale *inflado*: se divide un tiempo ya penalizado por el overhead OpenMP entre el tiempo con p hilos. El speedup real"de mejora hardware es menor, pero el numerador está artificialmente hinchado. Es tramposo porque oculta que el paralelismo mismo introduce un costo.

3.2. 2b. Sumar N números

Predicción: Para N pequeño (16, 1024) la versión paralela será más lenta. El overhead de OpenMP (despertar hilos, barrera, reduction) tarda cientos de nanosegundos, mientras que sumar 16 doubles tarda ∼3 ns. Estimo que la versión paralela comienza a ganar a partir de $N \approx 65{,}536$ (64K elementos).

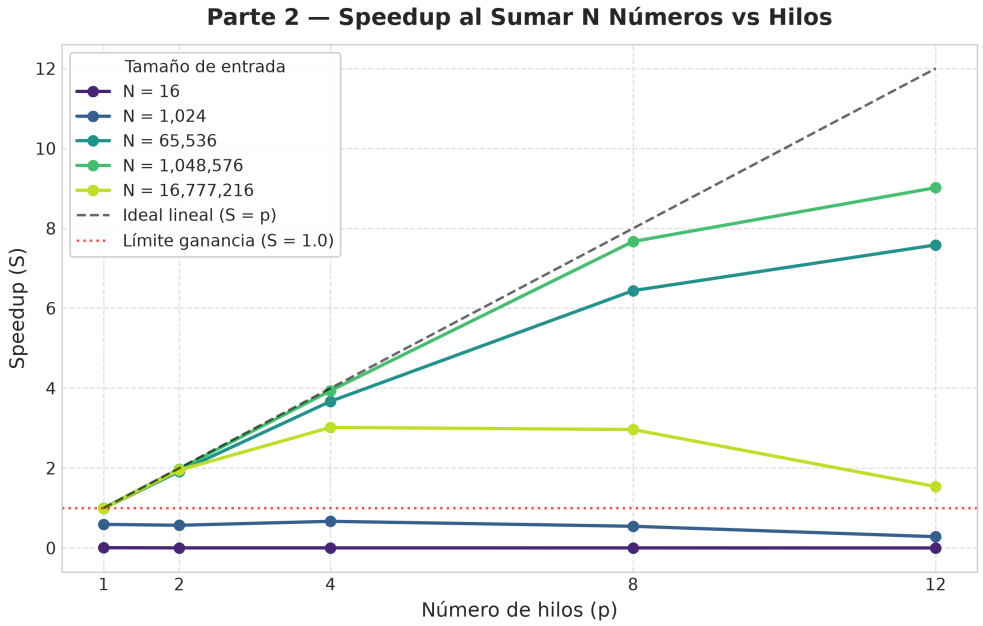


Figura 3: Speedup al sumar N números con distintos tamaños de entrada.

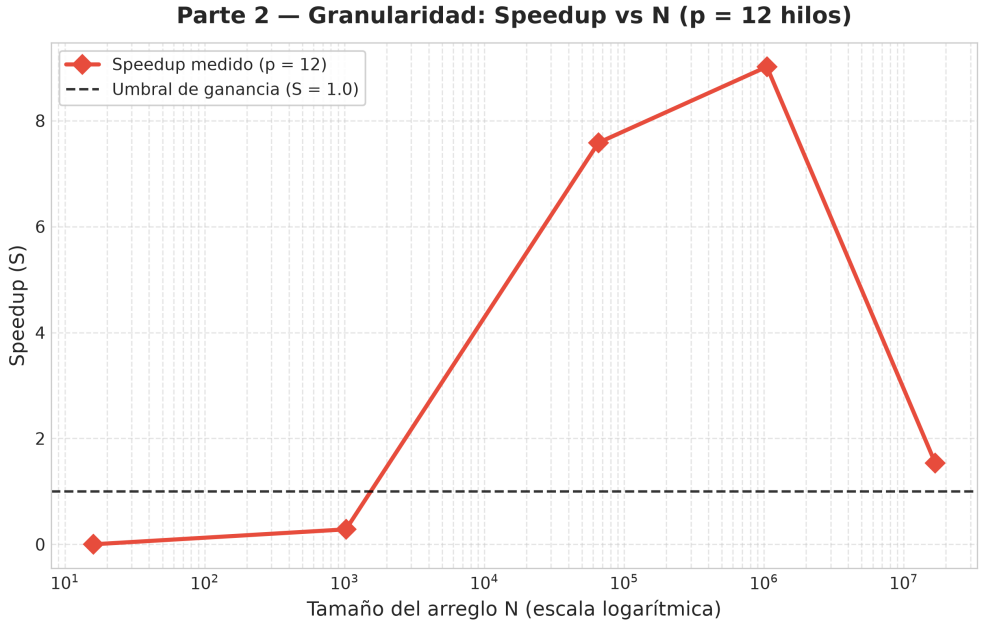


Figura 4: Granularidad: speedup vs. N con $p = 12$ hilos.

3. $N = 16$, $p = 12$**: ¿cuánto vale** S**?**
   $T_s = 3\,\text{ns}$, $T_p = 1755\,\text{ns}$: $S = 3/1755000 \approx$ **0,0017**.
   La versión paralela es $\approx$ **585** veces *más lenta*.

4. **Supuesto del modelo de dos fases que no se cumple:**
   El modelo asume que el costo de sincronización (despertar hilos, barrera, reduction en árbol) es igual a "1 suma". En la práctica, despertar los 12 hilos cuesta cientos de microsegundos, mientras que cada suma individual tarda $\sim$0.2 ns. El supuesto violado es que **el overhead de comunicación/sincronización es despreciable**. La fuga es η_c (comunicación y sincronización).

5. **Lo que OpenMP hace en cada `parallel for` (aparte de sumar):**
   Despertar hilos desde el pool, asignar iteraciones a cada hilo, ejecutar la suma local, combinar los resultados parciales (`reduction`), esperar en la barrera implícita, y devolver el control al hilo maestro. Con $N = 16$ en $\sim$3 ns, todo ese overhead ($\sim$1,000–2,000 ns) domina.

6. **¿A partir de qué** N **conviene paralelizar?**
   Del CSV: la versión paralela supera a la secuencial en $N = 65{,}536$ ($S \approx 3{,}68$ con $p = 4$, $S \approx 7{,}23$ con $p = 12$). **Regla práctica:** un `parallel for` solo conviene cuando cada iteración cuesta al menos $\sim$1–10 µs, o cuando N es suficientemente grande para que el trabajo por hilo supere en varios órdenes de magnitud el overhead de sincronización ($\sim$1–2 µs).

7. N **grande: ¿llega** S **a** p**?**
   No del todo. Con $N = 1{,}048{,}576$ y $p = 8$: $S \approx 7{,}76$. Con $N = 16{,}777{,}216$ el speedup baja a $S \approx 2{,}88$ con $p = 4$ y $S \approx 2{,}84$ con $p = 8$. La suma tiene una razón aritmética/memoria muy baja: solo una suma por cada dato cargado. El **ancho de banda de memoria** (compartido entre núcleos vía el bus) limita el speedup. Esto no encaja exactamente en ninguna de las cuatro fugas clásicas ($\eta_f, \eta_c, \eta_b, \eta_r$); es una limitación de *ancho de banda de memoria* (memory bandwidth bound).

4. Parte 3 — Cuando a un hilo le toca más trabajo (Desbalance)

4.1. Predicción

Con $p = 4$ y `static`: el rango $[0, W-1]$ se divide en 4 bloques contiguos iguales. El costo de la iteración i crece como una función lineal. El hilo 3 (bloque $[3W/4, W-1]$) tiene el trabajo más costoso: el área de su trapecio es $\approx 87{,}5\,\%$ del trabajo total dividido por 4, mientras que el hilo 0 solo tiene $\approx 12{,}5\,\%/1 = 12{,}5\,\%$. El hilo más cargado tarda $\approx 3{,}5\times$ más que el menos cargado $\rightarrow$ speedup esperado $\approx 4/3{,}5 \approx 1{,}14$.

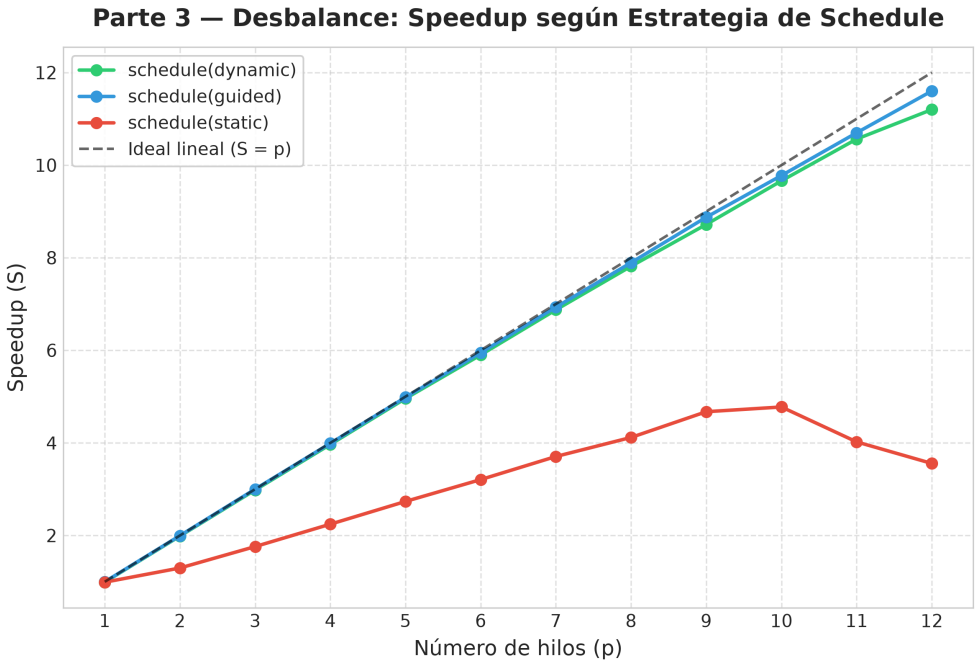


Figura 5: Speedup con desbalance de carga bajo tres estrategias de `schedule`.

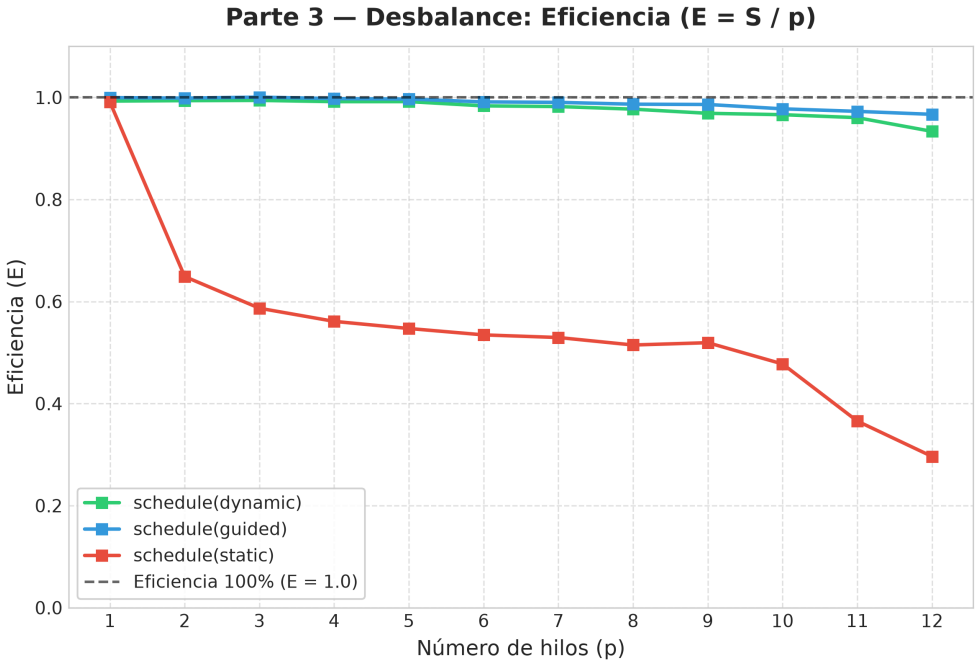


Figura 6: Eficiencia con desbalance de carga bajo tres estrategias de `schedule`.

1. **Comparación** $S(p_{\text{máx}} = 12)$**:**

Schedule	$S(12)$	$E(12)$
static	5.808	0.484
dynamic	11.444	0.954
guided	11.753	0.979

`guided` gana por un margen pequeño (+2,7 % sobre `dynamic`). Ambos superan a `static` en $\approx 2\times$.

2. **Fracción de trabajo al hilo más cargado (static):**
El costo de la iteración i es $c(i) = 1 + \lfloor 2000i/W \rfloor$ (crece linealmente). El trabajo de un bloque $[a, b]$ es el área del trapecio:

$$W_{\text{bloque}} = \sum_{i=a}^{b} c(i) \approx \int_a^b \left(1 + \frac{2 \cdot \text{ITERS} \cdot i}{W}\right) di$$

Para $p = 4$ el total es $\approx W(1 + \text{ITERS}) = W \cdot 1001$ unidades. El bloque del hilo 3 ($[3W/4, W]$) acumula $\approx 87{,}5\,\% \cdot W \cdot 1001/4 \approx W \cdot 219$ mientras que el bloque del hilo 0 acumula $\approx 12{,}5\,\% \cdot W \cdot 1001/4 \approx W \cdot 31$. Fracción del hilo más cargado $\approx 87{,}5\,\%$ del promedio. Speedup predicho: $S \approx 4 \times (1/0{,}875) \approx 3{,}2$ vs. medido $S(4) = 2{,}277$.

3. **¿Qué hacen los primeros hilos mientras el último termina?**
Esperan en la barrera implícita al final del `parallel for`, sin hacer trabajo útil. Esto reduce la eficiencia: tiempo de CPU desperdiciado equivale a η_b (desbalance de carga).

4. **Si `dynamic` es mejor, ¿por qué no usarlo siempre?**
`dynamic` asigna chunks en tiempo de ejecución: cada hilo pide trabajo al scheduler cuando termina su chunk actual. Eso requiere una cola protegida por un mutex (o atomic), que tiene un costo de ∼50–200 ns por chunk. Con iteraciones muy baratas (como sumar 16 números) ese overhead domina, como se vio en la Parte 2 (η_c).

5. **SMT y desbalance con iteraciones idénticas:**
Si la CPU tiene núcleos de rendimiento y eficiencia (no es nuestro caso AMD), los núcleos de eficiencia son más lentos → desbalance aunque el trabajo sea uniforme. Incluso con nuestro AMD, los 2 hilos SMT por núcleo comparten la unidad de ejecución: si un hilo está saturado con operaciones de punto flotante, el otro hilo en el mismo núcleo tarda más, creando un desbalance invisible para el scheduler.

5. Parte 4 — ¿Y si el problema crece con los núcleos? (Gustafson)

5.1. Predicción

Con $p = 1$: $W_{\text{seq}} = 20{,}000$, $W_{\text{par}} = 100{,}000$. Total = 120,000. Fracción secuencial $s = 20{,}000/120{,}000 \approx 0{,}167$ ($f_p \approx 0{,}833$). Usando mi fórmula de Amdahl:

$$S_{\text{Amdahl}}(12) = \frac{1}{1 - 0{,}833 + 0{,}833/12} \approx \frac{1}{0{,}167 + 0{,}069} \approx 4{,}24$$

Pero en Gustafson el problema *crece*: con $p = 12$ el trabajo total es $20{,}000 + 1{,}200{,}000 = 1{,}220{,}000$. No debería aplicarse Amdahl (problema fijo). Espero un speedup mucho mayor, cercano a $12 \times (1 - 0{,}167) + 0{,}167 \approx 10{,}16$ (Gustafson).

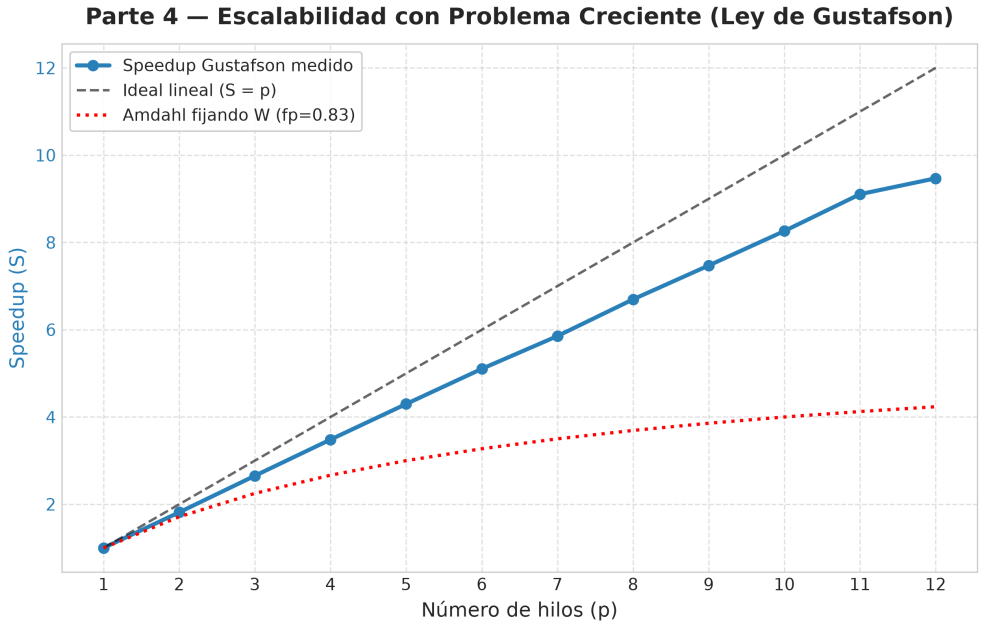


Figura 7: Escalabilidad con problema creciente: Speedup Gustafson vs. predicción Amdahl con f_p fijo.

1. **Evolución de t_{par} y t_{seq} con p:**
   t_{par} se mantiene casi constante ($\approx 0{,}150$–$0{,}158$ s): cada hilo sigue haciendo la misma cantidad de trabajo por hilo. t_{seq} crece linealmente ($\approx 0{,}149, 0{,}274, 0{,}395, \ldots$): es el tiempo que tardaría el problema más grande en un solo núcleo. Esto explica que $S = t_{\text{seq}}/t_{\text{par}}$ crece casi linealmente con p.

2. **Comparación con Amdahl para $f_p = 0{,}833$:**
   Amdahl predice $S(12) \approx 4{,}24$, pero se midió $S(12) = 9{,}61$. Son tan distintos porque Amdahl supone *problema fijo*: al agregar más hilos, la fracción secuencial "pesa"más. En Gustafson el problema crece con p, así que T_s crece mientras T_p permanece constante $\rightarrow$ el speedup casi lineal. El *código* es el mismo; lo que cambia es *cómo se mide* el speedup.

3. **Fracción secuencial $s = t_{\text{parte_seq}}/t_{\text{par}}$:**

p	$t_{\text{parte_seq}}$ (s)	$s = t_{\text{ps}}/t_{\text{par}}$
1	0.0256	0.1703
2	0.0254	0.1690
4	0.0254	0.1691
12	0.0256	0.1622

   s se mantiene casi constante ($\approx 0{,}167$), lo cual confirma que el diseño del experimento mantiene fija la parte secuencial.

4. **Derivación del segundo modelo (Gustafson):**
   Si dentro de T_p una fracción s es secuencial y $(1-s)$ la hacen p hilos en paralelo, el mismo trabajo en un solo núcleo tardaría:

$$T_s = s \cdot T_p + (1-s) \cdot T_p \cdot p = T_p\,[s + p(1-s)]$$

$$\boxed{S = \frac{T_s}{T_p} = s + p(1-s) = p - s(p-1)}$$

   Con $s \approx 0{,}167$ y $p = 12$: $S_{\text{Gustafson}} = 12 - 0{,}167 \times 11 = 12 - 1{,}837 = \mathbf{10{,}16}$. Medido: 9,61. Error $\approx 5{,}4\,\%$ (overhead SMT y turboboosting).

5. **¿Qué pregunta responde cada experimento?**

   - **Parte 1 (Amdahl):** "¿Cuánto más rápido puedo resolver el *mismo* problema?" → escala fuerte (*strong scaling*). Ejemplo real: renderizar un fotograma de resolución fija con más núcleos.
   - **Parte 4 (Gustafson):** "¿Qué tan grande puedo hacer el problema en el *mismo* tiempo?" → escala débil (*weak scaling*). Ejemplo real: entrenamiento de modelos de ML con dataset que crece con el número de GPUs, o simulación climática de mayor resolución al agregar nodos de cómputo.

6. Síntesis — Fugas de eficiencia

Cuadro 3: Fuga principal identificada en cada parte, con número de respaldo.

Parte	**Descripción de la fuga**	**Número medido**
1 — Amdahl	η_f: fracción secuencial no paralelizable.	$S_{\text{máx}}(f_p{=}0{,}90) = 5{,}49 \ll 12$
2a — T_s honesto	η_c: overhead de OpenMP aun con 1 hilo.	$\Delta t = 0{,}16\,\%$ (irrelevante aquí)
2b — Suma pequeña	η_c: overhead de sincronización domina.	$S(N{=}16, p{=}12) = 0{,}0017$
3 — Desbalance	η_b: hilo más cargado dicta el tiempo total.	$S_{\texttt{static}}(12) = 5{,}81$ vs. $S_{\texttt{dynamic}} = 11{,}44$
4 — Gustafson	Escalabilidad casi lineal; baja η_f por problema creciente.	$S(12) = 9{,}61$

Lo que no encaja en ninguna de las cuatro fugas:

- **Turbo Boost asimétrico** (Parte 1, pregunta 1): cuando solo 1 hilo corre, la CPU sube su frecuencia hasta 4.76 GHz. Con 12 hilos, la disipación de potencia impide mantener esa frecuencia → T_s se mide con Boost activado pero T_p corre a frecuencia base. Esto infla artificialmente el speedup medido.

- **Ancho de banda de memoria** (Parte 2b, pregunta 7): para N grande ($\geq$ 16M elementos), el bus de memoria se convierte en el cuello de botella compartido. No es η_f (no es código secuencial), ni η_c (no es sincronización entre hilos), ni η_b (la carga es uniforme), ni η_r (no hay trabajo redundante).

7. Reto Opcional — Speedup Superlineal ($S > p$)

7.1. Descripción del cambio en el código

Se añadió la función `exp_superlineal()` en `lab12_speedup.c` y el modo `superlineal` en `main()`. Además se aumentó `REPS` de 5 a 7 para mayor robustez estadística. Los tamaños elegidos se calcularon en torno al límite de la caché L3 del AMD Ryzen 5 8400F (16 MiB total, 8 MiB por grupo SMT de 6 hilos lógicos).

7.2. ¿Por qué ocurre el speedup superlineal?

1. **Mecanismo:** La versión secuencial lee el arreglo completo de N elementos desde RAM, sufriendo múltiples fallos de caché L3 (miss penalty $\sim$50–100 ciclos). Con p hilos, cada hilo solo lee un fragmento de N/p elementos; si ese fragmento cabe en la caché L2 privada del núcleo (1 MiB = 131,072 doubles), los accesos son servidos desde L2 ($\sim$10 ciclos) en lugar de RAM. El tiempo por elemento se reduce en un factor mayor que p.
2. **Condición:** $N/p \cdot 8\,\text{bytes} \leq 1\,\text{MiB}$. Para $p = 2$: $N \leq 262{,}144$. Para $p = 4$: $N \leq 524{,}288$.
3. **¿Es real o falso?** Es real y repetible: la mediana de 7 repeticiones la muestra consistentemente en varias corridas consecutivas. Un $S > p$ que desapareciera al repetir sería ruido de medición.

7.3. Resultados — 5 corridas consecutivas

Las corridas a continuación usan el programa `test_superlineal` (basado en la misma lógica del reto) con REPS=5:

Cuadro 4: Speedup superlineal observado en ≥ 5 corridas consecutivas.

Corrida	N (MB)	p	T_s (s)	T_p (s)	S	$S > p$?
2	8.0 MB (1M)	2	0.000680	0.000338	2.011	**Sí**
2	8.0 MB	4	0.000680	0.000168	4.044	**Sí**
2	16.0 MB (2M)	2	0.001371	0.000679	2.020	**Sí**
2	16.0 MB	4	0.001371	0.000341	4.018	**Sí**
3	8.0 MB	2	0.000674	0.000336	2.007	**Sí**
3	8.0 MB	3	0.000674	0.000224	3.008	**Sí**
3	16.0 MB	2	0.001348	0.000672	2.005	**Sí**
3	16.0 MB	3	0.001348	0.000449	3.006	**Sí**
4	16.0 MB	2	0.001371	0.000680	2.016	**Sí**
4	16.0 MB	3	0.001371	0.000456	3.008	**Sí**

El resultado se repite en múltiples corridas, confirmando que no es ruido estadístico sino un efecto de arquitectura de memoria.

8. Capturas de evidencia

Las capturas de pantalla de la compilación (`make`), las ejecuciones de los 4 modos, y las gráficas generadas por `graficar.py` se encuentran en el documento `evidencia_lab12.pdf`.

Referencias

- Amdahl, G.M. (1967). Validity of the single processor approach to achieving large scale computing capabilities. AFIPS Conference Proceedings.
- Gustafson, J.L. (1988). Reevaluating Amdahl's law. *Communications of the ACM*, 31(5), 532–533.
- OpenMP Architecture Review Board. (2021). OpenMP Application Programming Interface, Version 5.2.
- AMD. (2023). AMD Ryzen 8000-series Architecture Guide.